MILESTONE 1 · 评测口径说明

FVD 换了什么：从 pooled Fréchet 到 per-clip 平均

旧： video_metric / styleganv · first24 · 640 条 · pooled FVD ≈ 130

新： videovaet_fvd / videogpt · first52 · 642 条 · per-clip 均值 ≈ 970

结论先说：这不是一次“数值修正”，而是换了一个**估计量**。
旧数字（129.75 / 137.98 …）与新数字（969 / 985 …）不可换算、不可同表、不可相减。

2026-10-30
依据： FVD_SPEC.md （2026-10-29 生效）
AGENTS.md 第 5 条

适用仓库： text2video （代码） + text2video-trae （知识库）

TL;DR

一页看完：到底变了哪三件事

- **估计量变了**：旧 = 把 640 条生成 clip 的特征**拼成一个分布**，估 μ 和 Σ，算一次 Fréchet；新 = **每条 clip 与它自己的真值配成一对**，各自算一次 Fréchet，再对 642 对取算术平均。

- **时间窗变了**：旧 = 源 frame0..23 **连续 24 帧**；新 = 每条 N = min(52，源帧数)，真值经 N 帧 symlink 视图送进 FixedSample(52)， 86.6% 的 clip 用满 52 帧。

- **代码身份变了**：旧 = 调用外部目录 /home/wxy/video_metric；新 = 仓库内 vendored third_party/videovaet_fvd/， sha256 每次加载校验，带 verify / selftest 两个自检。

量的后果：同一批特征， per-clip 均值 1067.68 vs pooled 191.41 （≈ 5.6× ）。所以“新分数变差了”这种判断没有意义——先看本底 floor，再看排序。

背景

先对齐概念： FVD 到底在量什么

Fréchet Video Distance （Unterthiner et al., 2018）：把视频送进 I3D 取特征，再比较两组特征的多元高斯。

$$\mathrm{FVD} = \|\mu_r - \mu_g\|^2 + \mathrm{Tr}\left(\Sigma_r + \Sigma_g - 2\cdot(\Sigma_r \Sigma_g)^{\wedge}\tfrac{1}{2}\right)$$

μ = 特征均值，Σ = 特征协方差

- **特征**：I3D （Inception-v1, Kinetics-400 预训练）的 **400 维 logits** （softmax 之前）。不是 R(2+1)D 的 512 维池化特征——那是早期实现的历史错误。
- **两个分量**：均值项管“像不像”，协方差项管“分布形状 / 多样性像不像”。**谁被保留，决定了指标在量什么。**
- **没有物理单位**：FVD 的数值只在“同数据集、同帧窗、同预处理、同代码”内可比；论文也只是给经验尺度（差 < 50 人眼基本看不出）。
- **同分布也不为 0**：有限样本下真值 vs 真值也有距离，所以必须同时报 N 和 real-vs-real **本底**。

口径史

四代口径的演进：为什么会有这么多“ FVD”

代	时间	实现	帧窗口	聚合方式	量级
① 伪 FVD	2026-10 之前	torchvision R(2+1)D-18， 512 维池化特征	16 帧均匀	pooled	22–26 （**不是 FVD**）
② 本地 I3D	2026-10-21	tools/eval_fvd.py （已删除）	16 帧均匀	pooled	132–185 （ floor 74.2 ）
③ 上一版正式	2026-10-27	video_metric · method=styleganv	first24 连续	pooled	126–142 （ floor 84.9 ）
④ 现行	2026-10-29	third_party/videovaet_fvd （ videogpt ）	min(52，源帧数)	**per-clip 均值**	969–993 （ floor ≈1504 ）

①②③ 全部作废，只作追溯。同一份报告里如果出现两代数字并列，评审可以直接判无效。

旧

旧口径（2026-10-27 → 2026-10-29）： first24 + pooled

环节	旧口径做法
入口	tools/eval_video_metric_fvd.py → 用户目录 /home/wxy/video_metric 的 calculate_fvd(..., method='styleganv', only_final=True)
清单	test 单侧， **640 条**（ m1_test_first24_ids.txt ， ids SHA 6f96ad9d... ）
帧窗	源 frame0..23 **连续 24 帧**，不补帧；生成侧解码 24 帧
几何	源 256² → 上游 preprocess_single： tensor bilinear （ no-AA ） + **center crop 224** ，像素 [−1, 1]
聚合	640 条特征 → 一个 400 维高斯 → **一次 pooled Fréchet** （均值项 + 协方差项）
本底	real_split_half_fvd： 真值随机分两半，两半之间算 pooled Fréchet = **84.8977**
产物	reports/eval/m1_E*/fvd.json （ fvd 、 real_split_half_fvd 、 protocol ）

新

新口径（2026-10-29 起）： first52 + per-clip

环节	新口径做法
入口	tools/eval_videovaet_fvd.py → 仓库内 third_party/videovaet_fvd/ （VIDEOVAET_FVD_ROOT 可换 checkout 交叉验证）
清单	test 单侧，**全部 642 条源**（m1_test_first52_ids.txt， SHA feb5565065977755…）
帧窗	每条 N = min(52，源帧数)；真值经 **N 帧 symlink 视图** data/phoenix_frames_first52/；生成 images0000..N-1，帧数必须恰好 N
几何	解码后 **stretch 到 224×224** （cv2.INTER_LANCZOS4），**不保持长宽比、不 center crop**； ToTensor = x/128−1
聚合	逐 clip： calculate_fvd(…, method='videogpt', only_final=True)， test_batch_size=1 ⇒ **N=1** ⇒ 只有均值项；再 np.mean(per-clip)
本底	同一 verbatim 管线跑**真值互配**（clip i vs clip i+N/2） = **1503.97**
产物	fvd_videovaet.json （fvd_mean、 median/std/min/max、 floor、 window_histogram、 protocol）

最本质的一条

差异一： pooled Fréchet → per-clip 平均

旧：整个集合算一次距离

642 条生成 clip 的 I3D 特征 642×400 → 估 μ、Σ（一个 400 维高斯） → Fréchet 一次 均值 + 协方差 → **FVD ≈ 130**

新：每一对（生成，真值）各算一次，再平均

clip i：生成 400-d logits 均值 μ_g → clip i：真值 400-d logits 均值 μ_r → N=1 ⇒ 协方差项 不可估，只剩 ‖ Δμ‖² → 对 642 对求平均 **FVD ≈ 970**

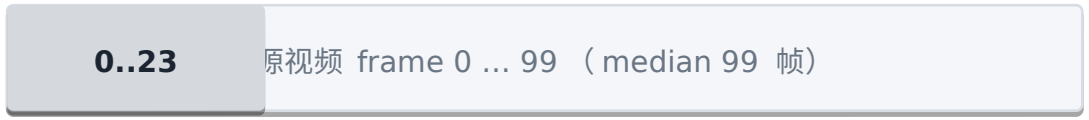
保留的东西不同：旧口径的协方差项会惩罚“生成的多样性不像真值”；新口径只问“这条 clip 的特征均值离它自己的真值有多远”。

配对 vs 不配对：新口径是**有监督的配对距离**（每对都对齐同一个说话人 / 同一句话），所以它能稳定低于“不相关真值对”的本底；旧口径是**分布间**距离，天生要大于同分布本底。两者比较的其实是不同的问题。

数据层

差异二： 24 帧连续窗口 → min(52，源帧数)

旧：只看开头 24 帧



生成也只解 24 帧；后面 76 帧（≈ 24%–50% 的时间）完全没进指标。

新：按源长度决定窗口 N



窗口取前 52 帧（ 86.6% 的 clip ）；源只有 17..51 帧时 N 取它自己的长度（ 48/44/…/16 ），两侧严格等长。

为什么必须做“ N 帧 symlink 视图”

- 包的默认行为是**读整段真值 → 均匀取 52 帧**。
- 整段真值常有 70–140 帧，而生成侧只有前 N 帧 → 两侧不是同一时间窗，指标就失去意义。
- 视图先按 N 把真值裁成 images0001..N （只建软链，不动像素），两侧再走 FixedSample(52)： N ≤ 52 时它是恒等或对**两侧同样**向下取整到 4 的倍数。
- **禁止补帧**：生成帧数必须恰好等于 N，否则入口直接报错——这道闸门就是防止把 24 帧旧产物当 52 帧评分。

细节但会影响数值

差异三：几何、清单、编码

项目	旧（first24 / styleganv）	新（first52 / videogpt）	后果
缩放几何	tensor bilinear （no-AA） + center crop 224	cv2.INTER_LANCZOS4 **stretch** 到 224×224	新口径**不保持长宽比**，I3D 看到的形变更大
像素区间	上游 preprocess_single → [−1, 1]	ToTensor： x/128 − 1 → [−1, 1]	数值等价，但插值核不同
id 清单	640 条（first24 可用清单）	**642 条**（全部 test 源，skipped = 0）	N 不同 ⇒ 不可跨表比较
帧数	固定 24，不补帧	min(52，源帧数)，不补帧	同上；新口径覆盖全片前段
编码路径	生成侧 PNG → tensor	生成侧 PNG → tensor （**不经 mp4 重编码**）	两侧都免编码损失

一句话：新口径不是“同一把尺子量得更细”，而是换了一把尺子——帧窗、几何、清单、聚合方式四处同时变。

治理

差异四：代码身份与可复现性

项目	旧	新
实现位置	外部目录 /home/wxy/video_metric （ VIDEO_METRIC_ROOT ）	仓库内 third_party/videovaet_fvd/ （ VIDEOVAET_FVD_ROOT 仅用于交叉验证）
完整性	SHA256 表写在文档里，加载时不校验	vendor/MANIFEST.sha256 ，**每次加载校验**； 7 个文件逐字节 pin
自检	无	videovaet-fvd verify + selftest （本机 0.5691 ）
入口职责	IO + 上游调用	入口只做帧发现 / 校验 / 视图与落盘，**指标数学全在包内**，禁止另写
旧实现	—	eval_fvd.py / eval_signvip_fvd.py / eval_video_metric_fvd.py / redecode_fvd_frames.py / fetch_i3d_weights.py 已删除，不得恢复

意义：以前“换了机器 / 换了副本，数字为什么不一样”要靠人查；现在加载即校验，不同机器只在浮点舍入级别有差（实测跨卡相对差 ~9e-5 ）。

汇总

一张表看完：口径对照

维度	旧口径	新口径（现行）
正式名称	video_metric / styleganv first24	videovaet_fvd / videogpt first52
特征	I3D-K400 400 维 logits	I3D-K400 400 维 logits （同）
帧窗	24 帧连续（ frame0..23 ）	min(52，源帧数)，真值走 N 帧视图
几何	bilinear + center crop 224	LANCZOS4 stretch 224×224
清单	640 条	642 条（ skipped 0 ）
聚合	**pooled**： 一次 Fréchet （均值 + 协方差）	**per-clip**： 逐对 Fréchet （ N=1 ，仅均值项）→ 平均
本底 floor	real_split_half_fvd = 84.90	真值互配 clip i vs i+N/2 = 1503.97
数值量级	126–142	969–993
报告字段	fvd 、 real_split_half_fvd	fvd_mean 、 median/std/min/ max 、 floor 、 window_histogram

实测

两代数字对照（并排放，只是为了说明不可相减）

旧： pooled · first24 · N=640 · floor 84.90

臂	改动	FVD
E5	文本全冻 12 层	128.53
E7	前缀注入	126.85*
E1	base	129.75
E4	motion loss	130.85
E6	全 12 层可训	137.98
E3	ref 层看 [ref;text]	141.83*

新： per-clip · first52 · N=642 · floor 1503.97

臂	改动	fvd_mean
E5	文本全冻 12 层	**969.43**
E3	ref 层看 [ref;text]	**985.06**
E7	前缀注入	**993.37**
E1 / E2 / E4 / E6	已排队重测	进行中
E9	1c+3a 交互臂	训练中

* E3/E7 由已删除的旧副本实现算出，内部也不可比。

新表排序 E5 < E3 < E7 （1.6% / 0.8% / 2.4%），三臂都在本底的 64–66%；旧表里各臂只差 ≤ 0.94%，且带 * 的两个数来自已删除的旧实现——这正是“换尺子”后必须整体重算、不能拿旧排序做结论的原因。

易被误读的点

为什么差一个数量级：拆开算给你看

pooled： μ 是 640 条 clip 的平均，clip 之间的个体差异在求平均时被抹平；协方差项再把“分布宽度”对齐。于是同一批视频之间只剩很小的残余距离（~130）。

per-clip（N=1）：每条 clip 只和自己的真值比，没有平均可借，比较的是**两条 clip 的 400 维 logits 均值差**。单条 clip 的 logits 均值本身波动大，平方后自然到几百上千。

同一个特征空间实测：同一批 SignViP 特征上，per-clip 均值 **1067.68**、pooled **191.41**，相差 ≈ 5.6 倍；本项目实测 969 与 130 相差 ≈ 7.5 倍。

所以：不存在 f(新) = 旧的换算。任何“新 969 相当于旧 129”的说法都是错的；能做的只有“同口径内重跑一遍、重新排序”。

附带的好处：per-clip 是配对比较，对“同一个说话人的外观 / 背景”这类共模因素不敏感，臂间差被放大（1.6%–2.4%，旧口径只有 ⩽ 0.94%）；代价是噪声也更大，所以规范要求同时报 median/std/min/max。

新口径下的使用规则（强制）

- **必须报全 5 项**：fvd_mean、n、skipped、floor.fvd_mean、逐 clip 窗口分布；缺一项即视为无效。
- **写全称**：FVD (videovaet_fvd videogpt I3D-K400 logits, per-clip window min(52，源帧数), 224^2 stretch, per-clip mean, N=642)。
- **禁止混表**：R(2+1)D（22–26）、16 帧（132–185）、32 帧 SignViP、video_metric/styleganv（126–142）、2026-10-29 上午的 24 帧过渡口径（1107/1112/1118）全部不得与新数字并列或相减。
- **不跨 N 比较**：fvd_mean 是逐 clip 平均，N 变化会改变尾部权重；对比必须同清单（ids SHA feb5565065977755…）。
- **文献数字不可相减**：RWTH-2014T 的 1025.45 是 pooled FVD，量纲不同，只能作量级参照。

判读习惯：先看 fvd_mean / floor 的比值，再看臂间相对差是否大于噪声（跨卡 ~9e-5、单臂 std≈390）。单 seed 下 2% 以内的差只能说“同量级”。

落地

当前进度与复现命令

臂	checkpoint	52 帧评测状态
E5 / E3 / E7	在另一台机器	**已完成：** 969.43 / 985.06 / 993.37 （floor 1503.97）
E1 / E2 / E4 / E6	本机 runs/m1_E{1,2,4,6}/final.pt	**已排队**，等卡自动起（reports/queue/jobs_m1_first52_20261030.txt）
E9	训练中（2×3090， 30k）	训完自动跑（/tmp/m1_E9_chain.sh）
E8	无 final.pt	不参与

```
third_party/videovaet_fvd/bin/videovaet-fvd verify      #  每次换机器 / 改代码先自检
python tools/eval_milestone.py --config RUN/config.yaml --checkpoint RUN/final.pt \
  --out reports/eval/<arm>_first52_videovaet_<date> --decode-frames 52 \
  --min-source-frames 12 --ids-file reports/eval/samples/m1_test_first52_ids.txt
```

参考： .trae/documents/FVD_SPEC.md （唯一来源）、 AGENTS.md 第 5 条、台账 exp-121…128 。