Milestone 1 ｜用受控实验选择条件注入方式

目标：在冻结 VAE 的 latent 空间生成手语视频，以 SignViP 原样 I3D-FVD 为主指标。

文本 + 首帧 → PixArt → 冻结 VAE → 视频

每帧 1 个 1024 维 latent；扩散预测 x_0

PixArt-α： 28 层 / 宽度 1152 / 16 个注意力头

全局条件只包含 timestep；不使用 pose / gloss / 光流

E1 基准：分层 cross-attention + 浅层可训练文本编码器

mT5： embedding + 前 3 层 encoder 可训练

条件布局： [text, text, text, ref] × 7

默认不加 motion loss，不加载 PixArt 预训练权重

共同训练与推理配方

训练 30,000 步 · 随机初始化

有效 batch 12 · bf16

主学习率 1e−4

文本学习率 1e−5 （base）

EMA 0.9999；默认评测 raw

DDIM 50 步 · CFG 2 · seed 42

里程碑生成长度使用 GT 长度

十臂矩阵｜每次主要改变一个因素

E1 是基准； E9 同时改变两项，用于检查双通路与 motion loss 的交互。

实验	相对 E1 的改动	要回答的问题
E1	基准： [T,T,T,R] × 7 分层 cross-attn	建立共同参照
E2	每层 cross-attn 都接收 [ref ; text]	所有层同时看两路是否更好
E3	text 层不变； ref 层接收 [ref ; text]	只让少量层同时看两路是否更好
E4	增加多尺度 motion loss	时序差分监督是否改善生成
E5	完整 12 层 mT5 冻结	深且冻结 vs 浅且训练
E6	完整 12 层 mT5 可训练	更强文本编码器是否有收益
E7	条件作为 self-attn 前缀；无 cross-attn	更换条件注入通路
E8	前缀 + cross-attn 双通路	两种通路能否互补
E9	E8 + motion loss	时序监督与双通路的交互
E10	加载可兼容的 PixArt block 预训练权重	检验初始化收益

本次结果包含 E1 / E2 / E3 / E4 / E7 ； 其余实验不在本次结果表中。

FVD 协议 | first24， 256 × 256 → 224 × 224

“256 × 256” 是统一源图像尺寸； I3D 实际输入为 224 × 224 。 FVD 越低越好。

步骤	当前固定设置
样本集合	PHOENIX test ； 源视频≥ 24 帧，固定有效清单 640 条 / 原 642 条
时间窗口	源 frame 0–23 连续 24 帧，包含条件参考帧；不补帧
统一源几何	RGB， PIL bilinear resize 至 256 × 256
官方预处理	短边缩至 224 → 中心裁剪 224^2 → [−1,1] ； bilinear ，无抗锯齿
视频特征	I3D / Kinetics-400 ， 400 维 softmax 前 logits
距离计算	SignViP 原始 frechet_distance ，使用同一份源码与 I3D 权重

跨模型必须使用相同 GT 、 ID 、帧数与尺寸； SignViP 对照的共同有效子集为 617 条。

评测脚本 | 本地封装输入，官方代码计算 FVD

在线核验：本地 third_party/signvip/fvd.py 与 SignViP main 源码逐字节一致。

① tools/eval_milestone.py

检查配置与固定清单 → 使用 checkpoint 生成视频 → 子进程调用 FVD 入口

② tools/eval_signvip_fvd.py

读取图像 / 视频、截取前 24 帧、统一 256 尺寸；校验源码与权重 SHA256

③ third_party/signvip/fvd.py （SignViP 原样文件）

get_fvd_feats → preprocess_single → I3D； frechet_distance → 特征统计与距离

官方仓库的验证链： train_stage2_multi_cond.py::log_valid
→ metrics/calculate_fvd.py （only_final=True）→ metrics/fvd/styleganv/fvd.py

采用相同 FVD 核心实现；官方训练期验证使用 dev / 32 帧 / 272×224，与本项目协议不同。

阶段结果｜保留本次提供的全部数值

first24 · 源图像 256×256 · SignViP I3D-FVD ↓；不同样本量分组展示，不作统一排名。

历史模型 / 外部参照	FVD ↓	样本量
SignViP	218.5075	617
prefix60k	232.1191	640
route_t_align_20k	303.6804	640
route_t_align_20k_ema	302.2961	640
route_t_align_20k_ema_k4	231.5626	640

Milestone 1	FVD ↓	样本量
E1 · base	129.7222	待核对
E2 · 全层拼接	142.3202	待核对
E3 · ref 层拼接	141.83	640
E4 · motion loss	130.8486	待核对
E7 · 前缀注入	128.4762	617

已确认可直接比较：共同 617 条上， E7 128.4762 vs SignViP 218.5075

FVD 绝对降低 90.0313，约 41.2%；仅说明该固定子集上的指标差异。

当前观察｜前缀注入值得保留，细小差距待验证

将“当前读数”与“严格结论”分开： FVD 不能替代语义准确性或完整视频质量评价。

01 已确认的对照

在共同 617 条上， E7 的 FVD 低于本次 SignViP 生成结果。

这不是与 SignViP 论文表格数字的直接比较。

02 Milestone 1 的初步读数

所列分数中 E7 最低， E1 接近； E2 / E3 更高。

E4 暂未显示出相对 E1 的数值改善。

03 下一轮汇总应先统一清单

核对 E1 / E2 / E4 的原始报告与 ID 哈希；全部方法统一 640 条，

或统一到与 SignViP 共同的 617 条，再做正式对照。

E7 与 E1 当前数值只差 1.2460 ；样本量未齐且缺少重复实验，暂不据此认定稳定优胜。